

## ЛАБОРАТОРНАЯ РАБОТА № 3.

### Методы многомерного поиска.

#### Цель работы:

1. Изучение алгоритмов многомерного поиска 1-го и 2-го порядка.
2. Разработка программ реализации алгоритмов многомерного поиска 1-го и 2-го порядка.
3. Вычисление экстремумов функции.

#### Методические указания.

##### 4.2.1. Метод наискорейшего градиентного спуска.

##### Стратегия поиска.

Стратегия решения задачи состоит в построении последовательности точек  $\{x^k\}$ ,  $k = 0, 1, \dots$ , таких, что  $f(x^{k+1}) < f(x^k)$ ,  $k = 0, 1, \dots$ . Точки последовательности  $\{x^k\}$  вычисляются по правилу  $x^{k+1} = x^k - \alpha^k \nabla f(x^k)$ , где точка  $x^0$  задается пользователем; величина шага  $\alpha^k$  определяется для каждого значения  $k$  из условия:

$$\varphi(\alpha^k) = f(x^k - \alpha^k \nabla f(x^k)) \rightarrow \min_{\alpha^k}.$$

Решение задачи  $\alpha^{*k} = \text{Arg min } f(x^k + \alpha^k d^k)$ , где  $d^k = -\nabla f(x^k)$ , может осуществляться с использованием необходимого условия минимума  $\frac{d\varphi(\alpha^k)}{d\alpha^k} = 0$  с последующей проверкой

достаточного условия минимума  $\frac{d^2\varphi(\alpha^k)}{d\alpha^{k2}} > 0$ . Такой путь может быть использован либо при простой минимизирующей функции  $\varphi(\alpha^k)$ , либо при аппроксимации достаточно сложной функции  $\varphi(\alpha^{*k}) = f(x^k - \alpha^k \nabla f(x^k))$  полиномом  $P(\alpha^k)$  (как правило, второй или третьей степени), и тогда условие  $\frac{d\varphi(\alpha^k)}{d\alpha^k} = 0$  замещается условием  $\frac{dP(\alpha^k)}{d\alpha^k} = 0$ , а условие  $\frac{d^2\varphi(\alpha^k)}{d\alpha^{k2}} > 0$  - условием  $\frac{d^2P(\alpha^k)}{d\alpha^{k2}} > 0$ .

Другой путь решения задачи  $\alpha^{*k} = \text{Arg min } f(x^k + \alpha^k d^k)$  связан с использованием численных методов, когда ищется  $\min_{\alpha^k \in [a, b]} \varphi(\alpha^{*k}) = \min_{\alpha^k \in [a, b]} f(x^k - \alpha^k \nabla f(x^k))$ , т.е. с использованием методов одномерного поиска. Границы интервала  $[a, b]$  задаются пользователем. При этом степень близости найденного значения  $\alpha^k$  к оптимальному значению  $\alpha^{*k}$ , удовлетворяющему условиям  $\frac{d\varphi(\alpha^k)}{d\alpha^k} = 0$  и  $\frac{d^2\varphi(\alpha^k)}{d\alpha^{k2}} > 0$ , зависит от задания интервала  $[a, b]$  и точности методов одномерной минимизации.

Построение последовательности  $\{x^k\}$ ,  $k = 0, 1, \dots$ , заканчивается в точке  $x^k$ , для которой  $\|\nabla f(x^k)\| < \varepsilon_1$ , где  $\varepsilon_1 > 0$  - заданное число, или если  $k \geq M$ ,  $M$  - предельное число итераций, или при двукратном одновременном выполнении неравенств  $\|x^{k+1} - x^k\| < \varepsilon_1$ ,  $|f(x^{k+1}) - f(x^k)| < \varepsilon_2$ , где  $\varepsilon_2$  - малое положительное число. Вопрос о том, может ли точка  $x^k$  рассматриваться как найденное приближение искомой точки локального минимума  $x^*$ , решается путем дополнительного исследования.

### Алгоритм.

**Ш.1.** Задать  $x^0$ ,  $\varepsilon_1 > 0, \varepsilon_2 > 0$ , предельное число итераций  $M$ . Найти градиент

$$\text{функции в начальной точке } \nabla f(x^0) = \left[ \frac{\partial f(x^0)}{\partial x_1}, \dots, \frac{\partial f(x^0)}{\partial x_n} \right]^T.$$

**Ш.2.** Положить  $k = 0$ .

**Ш.3.** Вычислить  $\nabla f(x^k)$ .

**Ш.4.** Проверить выполнение критерия окончания  $\|\nabla f(x)\| < \varepsilon_1$ :

а) если неравенство выполнено, то  $x^* = x^k$ ;

б) если нет, то перейти на Ш.6.

**Ш.5.** Проверить выполнение неравенства  $k \geq M$ :

а) если неравенство выполнено, то  $x^* = x^k$ ;

б) если нет, то перейти на Ш.6.

**Ш.6.** Вычислить величину шага  $\alpha^{*k} = \text{Arg min } f(x^k + \alpha d^k)$ , где  $d^k = -\nabla f(x^k)$ .

**Ш.7.** Вычислить  $x^{k+1} = x^k - \alpha^{*k} \nabla f(x^k)$ .

**Ш.8.** Проверить выполнение условий:  $\|x^{k+1} - x^k\| < \varepsilon_1, |f(x^{k+1}) - f(x^k)| < \varepsilon_2$ :

а) если оба условия выполнены при текущем значении  $k$  и  $k = k - 1$ , то  $x^* = x^{k+1}$ ; расчет окончен;

б) если хотя бы одно из условий не выполнено, то положить  $k = k + 1$  и перейти на Ш.3.

### Замечание 3.2.

Метод наискорейшего спуска гарантирует сходимость последовательности  $\{x^k\}$  к точке минимума для сильно выпуклых функций.

### 4.2.2. Метод Флетчера-Ривза и Полака-Рибьера.

#### Постановка задачи

Требуется найти безусловный минимум функции  $f(x)$  многих переменных, т.е. найти такую точку  $x^* \in R^n$ , что  $f(x^*) = \min_{x \in R^n} f(x)$  на множестве допустимых решений  $X \in R^n$ . При этом предполагается использование методов одномерного поиска  $\alpha^{*k} = \text{Arg min}_{\alpha^k \in R^1} f(x^k + \alpha^k d^k)$  для определения величины шага в направлении поиска  $d^k$ .

#### Стратегия поиска.

Стратегия метода Флетчера-Ривза (FR) состоит в построении последовательности точек  $\{x^k\}$ ,  $k = 0, 1, \dots$ , таких, что  $f(x^{k+1}) < f(x^k)$ ,  $k = 0, 1, \dots$ . Точки последовательности  $\{x^k\}$  вычисляются по правилу:

$$x^{k+1} = x^k + \alpha^k d^k, k = 0, 1, \dots; \quad (4.1.1.)$$

$$d^k = -\nabla f(x^k) + w^{k-1} d^{k-1}; \quad (4.1.2.)$$

$$d^0 = -\nabla f(x^0); \quad (4.1.3.)$$

$$w^{k-1} = \frac{\|\nabla f(x^k)\|^2}{\|\nabla f(x^{k-1})\|^2}. \quad (4.1.4.)$$

Точка  $x^0$  задается пользователем, величина шага  $\alpha^{*k}$  определяется для каждого значения  $k$  из условия  $\alpha^{*k} = \text{Arg min}_{\alpha^k \in R^1} f(x^k + \alpha^k d^k)$ . Решение задачи одномерной

минимизации может осуществляться либо из условия  $\frac{d\varphi(\alpha^k)}{d\alpha^k} = 0, \frac{d^2\varphi(\alpha^k)}{d\alpha^{k^2}} > 0$ , либо численно, с использованием методов одномерной минимизации, когда решается задача:

$$\varphi(\alpha^k) \rightarrow \min_{\alpha^k \in [a,b]}. \quad (4.1.5.)$$

При численном решении задачи определения величины шага степень близости найденного значения  $\alpha^k$  к оптимальному значению  $\alpha^{*k}$ , удовлетворяющему условиям  $\frac{d\varphi(\alpha^k)}{d\alpha^k} = 0, \frac{d^2\varphi(\alpha^k)}{d\alpha^{k^2}} > 0$ , зависит от задания интервала  $[a,b]$  и точности одномерной минимизации.

Вычисление величины  $w^{k-1}$  по формуле (4.1.4.) обеспечивает для квадратичной формы  $f(x) = \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j$  построение последовательности  $H$ -сопряженных направлений  $d^0, d^1, \dots, d^k, \dots$ , для которых  $\langle d^j, H d^i \rangle = 0, \forall i, j = 0, 1, \dots, k; i \neq j$ . При этом в точках последовательности  $\{x^k\}$  градиенты функции  $f(x)$  взаимно перпендикулярны, т.е.  $\langle \nabla f(x^{k+1}), \nabla f(x^k) \rangle = 0, k = 0, 1, \dots$ .

Для квадратичных функций  $f(x)$  с матрицей  $H > 0$  метод Флетчера-Ривза является конечным и сходится за число шагов, не превышающее  $n$  - размерность  $x$  вектора переменных.

При минимизации неквадратичных функций метод не является конечным, при этом следует отметить, что погрешность в решении задачи (4.1.5.) приводит к нарушению не только перпендикулярности градиентов, но и  $H$ -сопряженности направлений. Для неквадратичных функций, как правило, используется алгоритм Полака-Рибьера, когда в формулах (4.1.1. – 4.1.3.) величина  $w^{k-1}$  вычисляется следующим образом:

$$w^{k-1} = \begin{cases} \frac{\|\nabla f(x^k)\|^2}{\|\nabla f(x^{k-1})\|^2}, & k \notin J, \\ 0, & k \in J, \end{cases} \quad w^{k-1} = \begin{cases} \frac{\langle \nabla f(x^k), [\nabla f(x^k) - \nabla f(x^{k-1})] \rangle}{\|\nabla f(x^{k-1})\|^2}, & k \notin J, \\ 0, & k \in J, \end{cases}$$

где  $J = \{0, n, 2n, \dots\}$ . В отличие от алгоритма Флетчера-Ривза алгоритм Полака-Рибьера предусматривает использование итерации наискорейшего спуска через каждые  $n$  шагов. Построение последовательности  $\{x^k\}$  заканчивается в точке, для которой  $\|\nabla f(x^k)\| < \varepsilon_1$ , где  $\varepsilon_1 > 0$  - заданное число, или при  $k \geq M, M$  - предельное число итераций, или при двукратном одновременном выполнении двух неравенств  $\|x^{k+1} - x^k\| < \delta_2, |f(x^{k+1}) - f(x^k)| < \varepsilon_2$ , где  $\delta_2, \varepsilon_2$  - малые положительные числа. Вопрос о том, может ли точка  $x^k$  рассматриваться как найденное приближение искомой точки минимума, решается путем проведения дополнительного исследования.

### Алгоритм.

**Ш.1.** Задать  $x^0, \varepsilon_1, \delta_2, \varepsilon_2, M$  - предельное число итераций. Вычислить градиент  $\nabla f(x^0)$ .

**Ш.2.** Положить  $k = 0$ .

**Ш.3.** Вычислить  $\nabla f(x^k)$ .

**Ш.4.** Проверить выполнение критерия окончания  $\|\nabla f(x^k)\| < \varepsilon_1$  :

a) если критерий выполнен,  $x^* = x^k$ , расчет заканчивается;

б) если нет, то перейти на Ш.5.

**Ш.5.** Проверить условие  $k \geq M$  :

а) если неравенство выполняется, то расчет окончен и  $x^* = x^k$ ;

б) если нет, то при  $k = 0$  перейти на Ш.6., а при  $k \geq 1$  перейти на Ш.7.

**Ш.6.** Определить  $d^0 = -\nabla f(x^0)$ .

**Ш.7.** Определить

$$w^{k-1} = \frac{\|\nabla f(x^k)\|^2}{\|\nabla f(x^{k-1})\|^2}, \text{ или } w^{k-1} = \begin{cases} \frac{\langle \nabla f(x^k), [\nabla f(x^k) - \nabla f(x^{k-1})] \rangle}{\|\nabla f(x^{k-1})\|^2}, & k \notin J, \\ 0, & k \in J. \end{cases}$$

**Ш.8.** Определить  $d^k = -\nabla f(x^k) + w^{k-1}d^{k-1}$ .

**Ш.9.** Найти  $\alpha^{*k}$  из условия  $\alpha^{*k} = \text{Arg} \min_{\alpha^k \in R^1} f(x^k + \alpha^k d^k)$ .

**Ш.10.** Вычислить  $x^{k+1} = x^k + \alpha^k d^k$ .

**Ш.11.** Проверить выполнение условий  $\|x^{k+1} - x^k\| < \delta_2, |f(x^{k+1}) - f(x^k)| < \varepsilon_2$  :

а) в случае выполнения обоих условий в двух последовательных итерациях с номерами  $k$  и  $k-1$  расчет окончен, найдена точка  $x^* = x^k$ .

б) если не выполняется хотя бы одно из условий, полагаем  $k = k+1$  и переход на Ш.3.

#### 4.2.3. Метод Девидона-Флетчера-Пауэлла.

##### Постановка задачи

Пусть дана функция  $f(x)$ , ограниченная снизу на множестве  $R^n$  и имеющая непрерывные частные производные во всех его точках (т.е.  $f(x) \in C^1(X)$ ,  $X = R^n$ ).

Требуется найти локальный минимум функции  $f(x)$  на множестве допустимых решений  $X = R^n$ , т.е. найти такую точку  $x^* \in R^n$ , что  $f(x^*) = \min_{x \in R^n} f(x)$ .

##### **Стратегия поиска.**

Стратегия метода Девидона-Флетчера-Пауэлла (DFP) состоит в построении последовательности точек  $\{x^k\}$ , таких, что  $f(x^{k+1}) < f(x^k)$ ,  $k = 0, 1, \dots$ . Точки последовательности  $\{x^k\}$  вычисляются по правилу:

$$x^{k+1} = x^k - \alpha^{*k} G^{k+1} \nabla f(x^k), k = 0, 1, \dots, \quad (4.2.1.)$$

где  $G^{k+1}$  - матрица размера  $n \times n$ , являющаяся аппроксимацией обратной матрицы Гессе. Она вычисляется по правилу:

$$G^{k+1} = G^k + \Delta G^k, G^0 = E, \quad (4.2.2.)$$

$$\Delta G^k = \frac{\Delta x^k (y^k)^T}{(y^k)^T \Delta g^k} - \frac{G^k \Delta g^k (G^k \Delta g^k)^T}{(\Delta g^k)^T G^k \Delta g^k}, \quad (4.2.3.)$$

где  $\Delta x^k = x^{k+1} - x^k$ ,  $\Delta g^k = \nabla f(x^{k+1}) - \nabla f(x^k)$ .

Точка  $x^0$  задается пользователем, величина шага  $\alpha^{*k}$  определяется из условия:

$$\alpha^{*k} = \text{Arg} \min_{\alpha^k \in [a, b]} \varphi(x^k + \alpha^k d^k). \quad (4.2.4.)$$

Решение задачи (4.2.4.) может выполняться как из условия  $\frac{d\varphi(\alpha)}{d\alpha^k} = 0, \frac{d^2\varphi(\alpha)}{d\alpha^{k^2}} > 0$ , либо численно, с использованием методов одномерной минимизации, когда решается задача:  $\varphi(\alpha^k) \rightarrow \min_{\alpha^k \in [a, b]}$  оптимизации.

Формулы (4.2.2.), (4.2.3.) при аналитическом решении задачи (4.2.4.) обеспечивают построение последовательности  $\{G^k\}$  положительно определенных матриц, таких, что  $G^k \rightarrow H^{-1}(x^*)$  при  $k \rightarrow \infty$ . Следствием этого для квадратичной функции  $f(x) = \frac{1}{2} \langle Hx, x \rangle + \langle b, x \rangle$ ,  $H > 0$ , является тот факт, что направления  $d^k$ ,  $k = 0, 1, \dots$ , будут  $H$ -сопряженными и, следовательно, алгоритм DFP сойдется не более чем за  $n$  шагов.

Для неквадратичных функций  $f(x)$  алгоритм DFP перестаёт быть конечным и его сходимость зависит от точности решения задачи (4.2.4.). Глобальную сходимость алгоритма можно гарантировать лишь при его обновлении через каждые  $n$  шагов, т.е. когда в формуле (4.2.1.):

$$G^{k+1} = \begin{cases} E, k \in J; J = \{0, n, 2n, \dots\}, \\ G^k + \Delta G^k, k \notin J. \end{cases}$$

Построение последовательности  $\{x^k\}$  заканчивается в точке  $x^{*k}$ , для которой  $\nabla f(x^k) < \varepsilon_1$ , где  $\varepsilon_1$  - заданное число, или при  $k \geq M$  ( $M$  - предельное число итераций), или при двукратном одновременном выполнении двух неравенств:  $\|x^{k+1} - x^k\| < \delta_2$ ,  $|f(x^{k+1}) - f(x^k)| < \varepsilon_2$ , где  $\delta_2 > 0$ ,  $\varepsilon_2 > 0$  - малые положительные числа. Вопрос о том, может ли точка  $x^k$  рассматриваться как найденное приближение искомой точки  $x^*$  минимума, решается путем проведения дополнительного исследования.

#### Алгоритм.

- Ш.1. Задать  $x^0$ ,  $\varepsilon_1$ ,  $\delta_2$ ,  $\varepsilon_2$ ,  $M$  - предельное число итераций. Найти градиент  $\nabla f(x^0)$ .
- Ш.2. Положить  $k = 0$ ,  $G^0 = E$ .
- Ш.3. Вычислить  $\nabla f(x^k)$ .
- Ш.4. Проверить критерий окончания  $\|\nabla f(x^k)\| < \varepsilon_1$ :
  - а) если критерий выполнен,  $x^* = x^k$ , расчет заканчивается;
  - б) Если нет, то перейти на Ш.5.
- Ш.5. Проверить условие  $k \geq M$ :
  - а) если неравенство выполняется, то расчет окончен и  $x^* = x^k$ ;
  - б) если нет, то при  $k = 0$  перейти на Ш.10., а при  $k \geq 1$  перейти на Ш.6.
- Ш.6. Вычислить  $\Delta g^k = \nabla f(x^{k+1}) - \nabla f(x^k)$ .
- Ш.7. Вычислить  $\Delta x^k = x^{k+1} - x^k$ .
- Ш.8. Вычислить  $\Delta G^k = \frac{\Delta x^k (\Delta x^k)^T}{(\Delta x^k)^T \Delta g^k} - \frac{G^k \Delta g^k (\Delta g^k)^T G^{kT}}{(\Delta g^k)^T G^k \Delta g^k}$ .
- Ш.9. Вычислить  $G^{k+1} = G^k + \Delta G^k$ .
- Ш.10. Определить  $d^k = -G^{k+1} \nabla f(x^k)$ .
- Ш.11. Вычислить  $\alpha^{*k} = \text{Arg} \min_{\alpha^k \in [a, b]} f(x^k + \alpha^k d^k)$ .
- Ш.12. Вычислить  $x^{k+1} = x^k + \alpha^{*k} d^k$ .
- Ш.13. Проверить условия  $\|x^{k+1} - x^k\| < \delta_2$ ,  $|f(x^{k+1}) - f(x^k)| < \varepsilon_2$ :
  - а) в случае выполнения обоих условий в двух последовательных итерациях с номерами  $k$  и  $k-1$  расчет окончен, найдена точка  $x^* = x^{k+1}$ .
  - б) если не выполняется хотя бы одно из условий, полагаем  $k = k+1$  и переход на Ш.3.

#### 4.2.4. Метод Бroyдена-Флетчера-Гольдфарба-Шенно.(BFGS).

Обозначим

$$y_k = \Delta g_k = \nabla \varphi_{k+1} - \nabla \varphi_k; s_k = \Delta x_k = x^{k+1} - x^k.$$

Тогда

$$\tilde{H}^{k+1} y_k = s_k; \text{ и } H^{k+1} s_k = y_k.$$

Отсюда

$$H^{k+1} = H^k + \frac{y_k y_k^T}{y_k^T s_k} - \frac{H^k s_k s_k^T H^k}{s_k^T H^k s_k}$$

Такая замена обеспечивает более устойчивый процесс

поиска экстремума. Как видно из соотношений для  $H^{k+1}$  и  $\tilde{H}^{k+1}$  формулы

пересчета для DFP и BFGS взаимнообратны.

$$\tilde{H}^{k+1} = \tilde{H}^k + \frac{(s_k - \tilde{H}^k y_k) s_k^T + s_k (s_k - \tilde{H}^k y_k)^T}{s_k^T y_k} - \frac{(s_k - \tilde{H}^k y_k)^T y_k}{(s_k^T y_k)^2} s_k s_k^T,$$

$$\tilde{H}^{k+1} = \left( I - \frac{s_k y_k^T}{s_k^T y_k} \right) \tilde{H}^k \left( I - \frac{y_k s_k^T}{s_k^T y_k} \right) + \frac{s_k s_k^T}{s_k^T y_k}.$$

$$H^{k+1} = H^k + \frac{(y_k - H^k s_k) y_k^T + y_k (y_k - H^k s_k)^T}{y_k^T s_k} - \frac{(y_k - H^k s_k)^T s_k}{(y_k^T s_k)^2} y_k y_k^T,$$

$$H^{k+1} = \left( I - \frac{y_k s_k^T}{y_k^T s_k} \right) H^k \left( I - \frac{s_k y_k^T}{y_k^T s_k} \right) + \frac{y_k y_k^T}{y_k^T s_k}.$$

#### 4.2.4. Метод Левенберга-Марквардта.

##### Постановка задачи

Пусть дана функция  $f(x)$ , ограниченная снизу на множестве  $R^n$  и имеющая непрерывные вторые частные производные во всех его точках (т.е.  $f(x) \in C^2(X)$ ,  $X = R^n$ ).

Требуется найти локальный минимум функции  $f(x)$  на множестве допустимых решений  $X = R^n$ , т.е. найти такую точку  $x^* \in R^n$ , что  $f(x^*) = \min_{x \in R^n} f(x)$ .

##### **Стратегия поиска.**

Стратегия метода Левенберга-Марквардта (LM) состоит в построении последовательности точек  $\{x^k\}$ , таких, что  $f(x^{k+1}) < f(x^k)$ ,  $k = 0, 1, \dots$ . Точки последовательности  $\{x^k\}$  вычисляются по правилу:

$$x^{k+1} = x^k - [H(x^k) + \mu^k E]^{-1} \nabla f(x^k), k = 0, 1, \dots, \quad (4.3.1.)$$

где точка  $x^0$  задается пользователем,  $E$  - единичная матрица,  $\mu^k$  - последовательность положительных чисел, таких, что матрица  $[H(x^k) + \mu^k E]^{-1}$  положительно определена. Как правило, число  $\mu^0$  назначается как минимум на порядок больше, чем самый большой элемент матрицы  $H(x^0)$ , а в ряде стандартных программ полагается  $\mu^0 = 10^4$ . Если  $f(x^k - [H(x^k) + \mu^k E]^{-1} \nabla f(x^k)) < f(x^k)$ , то  $\mu^{k+1} = \frac{\mu^k}{2}$ . В

противном случае  $\mu^{k+1} = 2\mu^k$ . Легко видеть, что алгоритм Левенберга-Марквардта в зависимости от величины  $\mu^k$  на каждом шаге по своим свойствам приближается либо к алгоритму Ньютона, либо к алгоритму градиентного спуска.

Построение последовательности  $\{x^k\}$  заканчивается, когда либо  $\|\nabla f(x^k)\| < \varepsilon_1$ , либо число итераций  $k \geq M$ , где  $\varepsilon_1$  - малое положительное число, а  $M$  - предельное число итераций.

Вопрос о том, может ли точка  $x^k$  рассматриваться как найденное приближение искомой точки минимума, решается путем проведения дополнительного исследования.

### Алгоритм.

**Ш.1.** Задать  $x^0, \varepsilon_1, \delta_2, \varepsilon_2, M$  - предельное число итераций. Найти градиент  $\nabla f(x^0)$  и матрицу Гессе  $H(x^0)$ .

**Ш.2.** Положить  $k = 0, \mu^k = \mu^0$ .

**Ш.3.** Вычислить  $\nabla f(x^k)$ .

**Ш.4.** Проверить критерий окончания  $\|\nabla f(x^k)\| < \varepsilon_1$ :

а) если критерий выполнен,  $x^* = x^k$ , расчет заканчивается;

б) если нет, то перейти на Ш.5.

**Ш.5.** Проверить условие  $k \geq M$ :

а) если неравенство выполняется, то расчет окончен и  $x^* = x^k$ ;

б) если нет, то перейти на Ш.6.

**Ш.6.** Вычислить  $H(x^k)$ .

**Ш.7.** Вычислить  $H(x^k) + \mu^k E$ .

**Ш.8.** Вычислить  $[H(x^k) + \mu^k E]^{-1}$ .

**Ш.9.** Вычислить  $d^k = -[H(x^k) + \mu^k E]^{-1} \nabla f(x^k)$ .

**Ш.10.** Вычислить  $x^{k+1} = x^k - [H(x^k) + \mu^k E]^{-1} \nabla f(x^k)$ .

**Ш.11.** Проверить выполнение условия  $f(x^{k+1}) < f(x^k)$ :

а) если неравенство выполняется, то перейти на Ш.12;

б) если нет, перейти на Ш.13.

**Ш.12.** Положить  $k = k + 1, \mu^{k+1} = \frac{\mu^k}{2}$  и перейти на Ш.3.

**Ш.13.** Положить  $\mu^{k+1} = 2\mu^k$  и перейти на Ш.7.

**Замечание 4.1.** В окрестности точки минимума  $x^*$  метод Левенберга-Марквардта обладает скоростью сходимости, близкой к квадратичной.

### Задание.

Требуется найти минимум тестовой функции Розенброка:

$$f(x) = \sum_{i=1}^{n-1} [a(x_i^2 - x_{i+1})^2 + b(x_i - 1)^2] + f_0.$$

1. Методами сопряженных градиентов (методом Флетчера-Ривза и методом Полака-Рибьера).
2. Квазиньютоновским методом (Девидона-Флетчера-Пауэлла).
3. Методом Левенберга-Марквардта.

**Замечание 4.2.** В качестве методов одномерного поиска использовать любой из известных методов одномерного поиска.

**Варианты задания:**

1.  $a = 50, b = 2, f_0 = 10, n = 2$ ;
2.  $a = 150, b = 2, f_0 = 100, n = 3$ ;
3.  $a = 80, b = 3, f_0 = 110, n = 2$ ;
4.  $a = 250, b = 2, f_0 = 50, n = 2$ ;
5.  $a = 70, b = 5, f_0 = 30, n = 3$ ;
6.  $a = 30, b = 2, f_0 = 80, n = 4$ ;
7.  $a = 250, b = 2, f_0 = 300, n = 2$ ;
8.  $a = 158, b = 2, f_0 = 40, n = 2$ ;
9.  $a = 500, b = 2, f_0 = 10, n = 2$ ;
10.  $a = 350, b = 2, f_0 = 110, n = 2$ ;
11.  $a = 300, b = 5, f_0 = 15, n = 2$ ;
12.  $a = 200, b = 1, f_0 = 25, n = 2$ ;
13.  $a = 100, b = 15, f_0 = 15, n = 2$ ;
14.  $a = 500, b = 5, f_0 = 35, n = 2$ ;
15.  $a = 100, b = 3, f_0 = 15, n = 2$ ;
16.  $a = 140, b = 2, f_0 = 24, n = 2$ ;
17.  $a = 1000, b = 10, f_0 = 150, n = 2$ ;
18.  $a = 100, b = 2, f_0 = 45, n = 3$ ;
19.  $a = 220, b = 3, f_0 = 12, n = 2$ ;
20.  $a = 500, b = 15, f_0 = 25, n = 2$ ;
21.  $a = 30, b = 3, f_0 = 45, n = 3$ ;
22.  $a = 180, b = 2, f_0 = 15, n = 2$ ;
23.  $a = 200, b = 5, f_0 = 48, n = 3$ ;
24.  $a = 300, b = 25, f_0 = 250, n = 2$ ;
25.  $a = 10, b = 250, f_0 = 45, n = 3$ .

1. Найти все стационарные точки и значения функций соответствующие этим точкам.
2. Оценить скорость сходимости указанных алгоритмов и сравнить по времени получение результата оптимизации для разных методов.
3. Реализовать алгоритмы программированием на одном из языков высокого уровня (C++, C#, Python, Haskell и др.).
4. Отчет представить в стандартном виде (TEX, PDF).

**Требования к отчету.**

1. Отчет должен содержать:
  - 1.1. титульный лист;
  - 1.2. цель работы;
  - 1.3. постановку задачи;
  - 1.4. проверку решения на допустимость.
2. Исследование выполнить с помощью написанной Вами программы с результатами в графическом виде.
3. Кроме текста исследования следует привести также текст исходного кода программ.
4. Отчет оформляется в формате PDF желательно в редакторе TEX.



## Генетический алгоритм.

### Цель работы:

1. Изучение методов решения задач многоэкстремальной оптимизации на основе генетического алгоритма.
2. Разработка программы реализации генетического алгоритма.
3. Решение задачи многоэкстремальной оптимизации для заданных многоэкстремальных функций.

### Постановка задачи

Дана целевая функция  $f(x) = f(x_1, x_2, \dots, x_n)$ , определенная на множестве допустимых решений  $D \subseteq R^n$ . Требуется найти глобальные минимумы заданных функций  $f(x)$  на допустимом множестве  $D$ . То есть такую точку

$$x^e = \operatorname{Arg} \min_{x \in D} f(x), \text{ где } x = (x_1, \dots, x_n)^T, D = \{x | x_i \in [\alpha, \beta], i = 1, \dots, n\}. \quad (1)$$

Задача поиска максимума целевой функции  $f(X)$  сводится к задаче поиска минимума путем замены знака перед функцией на противоположный:

$$f(x^e) = \max_{x \in D} f(x) = -\min_{x \in D} [-f(x)].$$

### Стратегия поиска

Генетические алгоритмы имитируют природные способы оптимизации, присущие процессам эволюции живых систем. А именно:

- генетическое наследование;
- изменчивость;
- естественный отбор.

**Целевая функция**  $f(x)$  соответствует природному понятию **приспособленности** живого организма. Вектор переменных  $x = (x_1, \dots, x_n)^T$  целевой функции называется **фенотипом**, а отдельные его параметры – **признаками**  $i = 1, 2, \dots, n$ .

Любой живой организм может быть представлен своим генотипом и фенотипом.

**Генотип** – это совокупность наследственных признаков, информация о которых заключена в хромосомном наборе генов.

**Фенотип** – совокупность всех признаков и свойств организма, формирующихся в процессе взаимодействия его генотипа и внешней среды. Каждый ген имеет своё отражение в фенотипе.

**Генетические алгоритмы** ведут поиск решения на уровне генотипа. Каждую координату  $x_i$  вектора  $x = (x_1, \dots, x_n)^T \in D$  представляют в некоторой форме  $s_i$ , удобной для использования в генетическом алгоритме и называется **геном**. Для этого необходимо выполнить преобразование, в общем случае не взаимно однозначное, вектора переменных  $x = (x_1, \dots, x_n)^T \in D$  в некоторую структуру  $s = (s_1, s_2, \dots, s_n)^T \in S$ , называемую **хромосомой**

(**генотипом, особью**):  $D \xrightarrow{e} S$ , где  $e$  функция кодирования,  $S$  - пространство представлений (как правило  $D \neq S$ ).

Для того, чтобы восстанавливать по хромосоме решение, необходимо задать обратное преобразование  $S \xrightarrow{e^{-1}} D$ , где  $e^{-1}$  - функция декодирования.

В пространстве представлений  $S$  вводится так называемая **функция приспособленности (функция фитнеса)**  $\mu(s) : S \xrightarrow{\mu} R$ , где  $R$  - множество вещественных

чисел, аналогичная целевой функции  $f(x)$  на множестве  $D$ . Функция  $\mu(s)$  может быть любая функция, удовлетворяющая условию:

$$\forall x^1, x^2 \in D: s^1 = e(x^1), s^2 = e(x^2), s^1 \neq s^2, \text{ если } f(x^1) > f(x^2), \text{ то } \mu(s^1) > \mu(s^2).$$

При решении используются конечные наборы:

$$I = \{s^k = (s_1^k, s_2^k, \dots, s_n^k)^T, k = 1, 2, \dots, m\} \subset S$$

Возможных решений, называемых **популяциями**, где  $s^k$  - хромосомы с номером  $k$ ,  $m$  - размер популяции,  $s_i^k$  - ген с номером  $i$   $k$ -той популяции.

Затем осуществляется обратное преобразование:

$$x^e = e^{-1}(s^*).$$

Различают два способа кодирования:

1. Бинарное кодирование.
2. Вещественное кодирование.

Будем использовать второй вариант кодирования. В этом случае целевая функция может использоваться непосредственно как функция фитнеса. Тогда в качестве функции фитнеса  $\mu(x)$  получается как преобразование целевой функции, т.е. *функция фитнеса*

$\mu(x): D \xrightarrow{\mu} R$ , где  $R$  - множество вещественных чисел, аналогична целевой функции  $f(x)$ .

Функцией  $\mu(x)$  может быть любая функция, удовлетворяющая следующему условию:

$$\forall x^1, x^2 \in D: x^1 \neq x^2, \text{ если } f(x^1) > f(x^2), \text{ то } \mu(x^1) > \mu(x^2).$$

Решение исходной оптимизационной задачи  $f(x^*) = \min_{x \in D} f(x)$  сводится к поиску решения  $x_\mu^*$  другой оптимизационной задачи:

$$\mu(x_\mu^*) = \max_{x \in D} \mu(x). \quad (2)$$

В силу выбора функции  $\mu(x)$ , решение задач (1) и (2) (хромосома) совпадают:

$$x^e = x^* = \text{Arg} \min_{x \in D} f(x) = \text{Arg} \max_{x \in D} \mu(x) = x_\mu^*. \quad (3)$$

При решении задачи (2) используются конечные наборы  $I = \{x^k = (x_1^k, \dots, x_n^k)^T, k = 1, 2, \dots, Mp\} \subset D$  возможных решений, называемых *популяциями*, где  $x^k$  - хромосома с номером  $k$ ,  $M$  - размер популяции,  $x_i^k$  - ген с номером  $i$ .

## Генетический алгоритм.

### Ш.1. Формирование исходной популяции.

Ш.1.1. Задается номер популяции  $t = 0$ , максимальное количество популяций  $Np$ , номер итерации цикла  $k = 1$ , размер популяции  $Mp$ .

Ш.1.2. Случайным образом выбирается начальная точка  $x^0$  - исходная хромосома. Она может быть выбрана как внутренняя точка гиперкуба области допустимых значений  $D$ . Из этой точки формируется исходная популяция. Для этого с помощью равномерного распределения на единичном отрезке  $[0,1]$   $Mp$  раз генерируется последовательность из  $n$  случайных точек  $\{P_i^{0k}\}_{i=1,n}^{k=1,Mp}$ ,  $i = 1, \dots, n$ ;  $k = 1, \dots, Mp$ . Используя линейное преобразование, каждая точка отображается на соответствующий ей промежуток  $[\alpha, \beta]$ :  $P_i^k = (\beta_i - \alpha_i)P_i^{0k} + \alpha_i$ . Составляя векторы из точек последовательности  $\{P_i^k\}$  при фиксированных  $k$ , получаем  $Mp$  начальных векторов  $x^k = (x_1^k, \dots, x_n^k)^T$ ,  $x_i^k = P_i^k$ ,  $i = 1, \dots, n$ , координаты которых  $x_i$  имеют равномерное распределение на отрезках  $[\alpha_i, \beta_i]$ ,  $i = 1, \dots, n$ .

Таким образом, может быть сформирована начальная популяция

$$I_0 = \{x^k, k = 1, \dots, Mp \mid x^k = (x_1^k, x_2^k, \dots, x_n^k) \in D\}.$$

Ш.1.3. Вычисляется значение функции фитнеса для каждой особи

$$x^k \in I_0 : \mu_k = \mu(x^k), k = 1, \dots, Mp \text{ и популяции } I_0 \text{ в целом } \mu = \sum_{k=1}^{Mp} \mu_i.$$

### Ш.2. Отбор (селекция).

Селекция – это операция, которая осуществляет отбор особей (хромосом)  $x^k$  в соответствии со значениями функции фитнеса  $\mu(x^k)$  для последующего их скрещивания.

Ш.2.1. Вычислить кумулятивную вероятность  $q_i = \sum_{j=1}^i \mu_j(x^j), i = 1, 2, \dots, Mp$ .

Ш.2.2. Сформировать случайное действительное число  $r$  в интервале  $(0, Mp]$ .

Ш.2.3. Выбрать  $i$ -ю хромосому  $x^i$  ( $1 \leq i \leq Mp$ ) так, чтобы  $q_{i-1} < r \leq q_i$ .

Ш.2.4. Перейти на Ш.2.2. до тех пор, пока не будет сформирована новая популяция ( $while(i \leq Mp)$ ).

### Ш.3. Кроссинговер (скрещивание).

Скрещивание – это операция, при которой из нескольких, обычно двух хромосом (особей), называемых родителями, порождается одна или несколько новых, называемых потомками.

Ш.3.1. Определяется параметр  $Pc \in (0, 1]$  как вероятность кроссинговера. Эта вероятность дает ожидаемое число  $Pc \cdot Mp$  хромосом, подвергаемых операции кроссинговера.

Ш.3.2. Для операции кроссинговера выполняется процесс, повторяющийся от  $i = 1$  до  $Pc \cdot Mp$ : формируется случайное действительное число  $r$  из сегмента  $[0, 1]$ , при этом, если  $r < Pc$ , то хромосома  $x^i$  выбирается как родительская.

Ш.3.3. Отбираются пары родительских хромосом  $(x^i, x^j)$ , где  $i \neq j$ . Действие оператора кроссинговера осуществляется следующим образом:

Ш.3.4. Формируется случайное число  $c \in (0, 1)$ , затем оператор кроссинговера, действующий на исходные пары  $(x^i, x^j)$ , производит две хромосомы потомки  $X$  и  $Y$ :

$$X = c \cdot x^i + (1 - c) \cdot x^j, \quad Y = (1 - c) \cdot x^i + c \cdot x^j.$$

Ш.3.5. Если допустимое множество является выпуклым, то кроссинговер обеспечивает допустимость обоих потомков, в случае если допустимы оба родителя. Следует проверить допустимость каждого потомка перед тем, как он будет включен в новую популяцию. Если оба потомка являются допустимыми, тогда родители заменяются этими потомками. Если это не так, сохраняется допустимый потомок, если он существует, а затем вновь выполняется оператор кроссинговера с новым значением случайного числа  $c$  до тех пор, пока не будут получены два новых допустимых потомка или не будет превышено заданное число циклов. В этом случае осуществляется замена родителей только теми (сохраненными ранее) потомками, которые оказались допустимыми.

### Ш.4. Мутация.

Мутация – это преобразование хромосомы, случайно изменяющее один или несколько из её генов. Оператор мутации предназначен для того, чтобы поддерживать разнообразие особей в популяции.

Ш.4.1. Определим параметр  $Pm \in (0, 1]$  как вероятность мутации. Эта вероятность дает ожидаемое число  $Pm \cdot Mp$  хромосом, подвергаемых операции мутации.

Ш.4.2. Для операции мутации выполняется процесс, повторяющийся от  $i = 1$  до  $Pm \cdot Mp$ : формируется случайное действительное число  $r$  из сегмента  $[0,1]$ , при этом, если  $r < Pm$ , то хромосома  $x^i$  выбирается как родительская для операции мутации. Для каждой выбранной родительской хромосомы  $x^i$ , обозначенной как  $Z = (x_1, x_2, \dots, x_n)$ , производится мутация.

Ш.4.3. Поочередно рассматривается каждый потомок из ожидаемого числа  $Pm \cdot Mp$  хромосом. Среди генов выбранной родительской хромосомы  $Z = (x_1, x_2, \dots, x_n)$  случайно (с вероятностью  $1/n$ ) выбирается один с номером  $p \in (1, 2, \dots, n)$  подлежащий замене. Его новое значение  $x_p^M$  случайным образом выбирается из промежутка  $[\alpha_p, \beta_p]$  изменения выбранной координаты  $x_p$ .

### Ш.5. Формирование новой популяции.

Ш.5.1. С равной вероятностью из потомков мутантов предыдущего шага выбирается один  $x^M = (x_1, x_2, \dots, x_p^M, \dots, x_n)$ .

Ш.5.2. Выбранный потомок добавляется в популяцию вместо хромосомы, которой соответствует наименьшее значение функции фитнеса (наихудшее из допустимых значений).

Ш.5.3 Вычисляется значение функции фитнеса для мутантного потомка  $\mu_M = \mu(x^M)$ .

Ш.5.4. Проверка условий:

Ш.5.4.1. Если  $k < Mp$ , то  $k = k + 1$  и переход на Ш.2.

Ш.5.4.2. Если  $k = Mp$ , то  $t = t + 1$  и переход на Ш.6.

### Ш.6. Проверка условия останова генетического алгоритма.

Условием окончания работы генетического алгоритма является формирование заданного количества популяций  $t = Nr$ .

Ш.6.1. Если условие не выполнено, то полагаем  $k = 1$  и переход на Ш.2.

Ш.6.2. Если условие окончания работы выполнено, то в качестве решения (приближенного) задачи  $\mu(x_\mu^*) = \max_{x \in D} \mu(x)$  выбирается особь с лучшим значением функции фитнеса из текущей популяции:  $x_\mu^* \cong x_\mu^e = \text{Arg max } \mu(x^k)$ , а по нему определяется приближенное решение поставленной задачи  $f(x^*) = \min f(x) : x^* = x_\mu^*$ .

**Замечание 1.** В качестве функции фитнеса можно использовать обратную целевую функцию  $\mu(x) = \frac{1}{f(x)}$ .

**Замечание 2.** Обычно размер популяции выбирают в пределах 30-60 особей.

**Замечание 3.** Вероятность кроссинговера принимается равной  $Pc = 0.3 - 0.5$ , вероятность мутации  $Pm = 0.05 - 0.2$ .

